BÀI 2
GIỚI THIỆU VỀ KHOA HỌC DỮ LIỆU

1. Khoa học dữ liệu

a. Khái niệm về khoa học dữ liệu

- Thuật ngữ “Khoa học dữ liệu” ban đầu phát sinh trong môi trường kinh doanh thông minh BI (Business Intelligence).
- Khoa học dữ liệu là bước phát triển tiếp theo của khoa học thống kê, khai phá dữ liệu, phát hiện tri thức trong dữ liệu,...

1. Khoa học dữ liệu

a. Khái niệm về khoa học dữ liệu

Khoa học dữ liệu:

- Là lĩnh vực liên ngành sử dụng các phương pháp khoa học, quy trình, công cụ của các ngành như toán học và thống kê, khoa học máy tính kết hợp với kiến thức chuyên môn trong các lĩnh vực ứng dụng như kinh doanh, tài chính ngân hàng, y tế, giáo dục,... nhằm rút ra được những hiểu biết sâu sắc từ dữ liệu.

Hình 1. Minh hoạ Khoa học dữ liệu là lĩnh vực liên ngành

1. Khoa học dữ liệu

a. Khái niệm về khoa học dữ liệu

- Khoa học dữ liệu nằm ở phần giao của "Toán học và thống kê" với "Khoa học máy tính" và "Tri thức chuyên môn thực tế" của lĩnh vực ứng dụng cụ thể.

- Học máy là một bộ phận của Khoa học máy tính và các phương pháp, công cụ, quy trình của nó được dùng trong Khoa học dữ liệu.

- Để xử lí dữ liệu, cần dùng máy tính (Khoa học máy tính) kết hợp với hiểu biết chuyên môn trong lĩnh vực ứng dụng.

Hình 1. Minh hoạ Khoa học dữ liệu là lĩnh vực liên ngành

1. Khoa học dữ liệu

a. Khái niệm về khoa học dữ liệu

Các mục tiêu cụ thể của khoa học dữ liệu

- Phân tích và trực quan hoá dữ liệu → Phát hiện được những vấn đề cần giải quyết
- Xây dựng mô hình dự đoán, dự báo → Xây dựng mô hình có khả năng dự đoán sự kiện tương lai
- Tối ưu hoá quyết định → Dựa vào thuật toán tối ưu để đưa ra quyết định tối ưu nhất
- Phát hiện tri thức → Tìm ra các mối quan hệ, quy luật trong dữ liệu -> Tri thức mới

1. Khoa học dữ liệu

b. Các giai đoạn của một dự án khoa học dữ liệu

Hình 2. Các giai đoạn của một dự án Khoa học dữ liệu

1. Khoa học dữ liệu

b. Các giai đoạn của một dự án khoa học dữ liệu

1. Xác định vấn đề

Hiểu rõ những vấn đề mà tổ chức, doanh nghiệp cần giải quyết. Từ đó, có thể xác định một số giả thuyết cần kiểm tra, đánh giá và quyết định.

2. Thu thập dữ liệu

Sau khi hiểu rõ vấn đề, cần thu thập dữ liệu liên quan từ nhiều nguồn khác nhau.

Trong nhiều trường hợp, tập dữ liệu thu thập được thường rất lớn.

1. Khoa học dữ liệu

b. Các giai đoạn của một dự án khoa học dữ liệu

3. Chuẩn bị dữ liệu

- Lựa chọn dữ liệu.
- Tích hợp dữ liệu từ nhiều nguồn.
- Làm sạch dữ liệu, xử lý các giá trị còn thiếu, không chính xác, loại bỏ ngoại lệ.
- Biểu diễn dữ liệu dưới dạng phù hợp để sử dụng trong các mô hình phân tích.

4. Phân tích dữ liệu

- Chọn lọc một số yếu tố quan trọng nhằm giải quyết vấn đề
- xây dựng các mô hình dự báo và phát triển kiến thức mới trong lĩnh vực hoạt động của tổ chức, doanh nghiệp

1. Khoa học dữ liệu

b. Các giai đoạn của một dự án khoa học dữ liệu

5. Đánh giá và giải thích

- Sử dụng các tiêu chí cụ thể để đánh giá chất lượng mô hình.
- Giải thích tác động của mô hình đến hoạt động của tổ chức, doanh nghiệp.
- Kiểm tra, đánh giá mô hình để triển khai.

6. Ra quyết định và triển khai

Sau các đánh giá nghiêm ngặt, kết quả phân dữ liệu được trình bày cho cấp lãnh đạo quản lý tổ chức, doanh nghiệp để làm cơ sở ra quyết định và triển khai thực tế.

1. Khoa học dữ liệu

b. Các giai đoạn của một dự án khoa học dữ liệu

Ví dụ minh hoạ

Lãnh đạo một cảng hàng không nhận thấy số lần máy bay chậm giờ cất cánh có xu hướng tăng là một vấn đề cần giải quyết. Một tổ dự án được giao nhiệm vụ đề xuất phương án cải tiến quy trình nghiệp vụ để giải quyết vấn đề trên. Một nhiệm vụ trong dự án là phân tích dữ liệu nhằm mục đích lập kế hoạch tốt hơn. Việc thực hiện nhiệm vụ này có thể coi là một dự án Khoa học dữ liệu nhỏ.

1. Khoa học dữ liệu

b. Các giai đoạn của một dự án khoa học dữ liệu

<u>Xác định vấn đề:</u>

Số lượng máy bay chậm giờ cất cánh

→

Số lượng hành khách qua sân bay (biến động tuỳ theo những thời gian khác nhau

Phân tích dữ liệu để dự báo lượng hành khách qua sân bay trong tương lai.

Lập kế hoạch ngắn hạn giúp phân bổ tốt hơn nguồn lực để đáp ứng yêu cầu công việc có biến động theo thời gian.

1. Khoa học dữ liệu

b. Các giai đoạn của một dự án khoa học dữ liệu

Thu thập dữ liệu

Tổ dự án cần thu thập các số liệu thống kê liên quan để có thể giải quyết vấn đề đã xác định.

Ví dụ: Số lượng hành khách qua sân bay theo từng thời điểm, số lần máy bay chậm giờ cất cánh và nguyên nhân.

1. Khoa học dữ liệu

b. Các giai đoạn của một dự án khoa học dữ liệu

<u>Chuẩn bị dữ liệu:</u>

Xác định những thuộc tính đặc trưng nào cần được phân tích.

Xử lí các số liệu còn thiếu hay xoá bỏ các số liệu trùng lặp, không chính xác.

Biểu diễn dữ liệu dưới dạng phù hợp để sẵn sàng áp dụng mô hình phân tích dữ liệu. Với ví dụ này, mô hình dữ liệu phù hợp là chuỗi thời gian.

1. Khoa học dữ liệu

b. Các giai đoạn của một dự án khoa học dữ liệu

Phân tích và khai phá dữ liệu

Phân tích dự báo dùng chuỗi thời gian để dự báo số lượng hành khách qua sân bay trong các tháng tiếp theo.

Đánh giá và giải thích

Mô hình dự báo dữ liệu bằng chuỗi thời gian có tham số để xác định độ tin cậy của kết quả dự báo.

Kết hợp độ tin cậy của mô hình lý thuyết và yêu cầu ứng dụng thực tế sẽ đánh giá được sự phù hợp để sử dụng trong việc lập kế hoạch ngắn hạn.

Đánh giá và giải thích tác động của việc cải tiến, đổi mới quy trình nghiệp vụ

2. Một số thành tựu của khoa học dữ liệu

a. Dự án Bộ gen người HGP

Dự án Bộ gen người HGP (Human Genome Project) kéo dài 13 năm (từ 1990 đến 2003) và tiêu tốn khoảng 3 tỷ USD là một nỗ lực quốc tế lớn nhằm nghiên cứu cấu trúc và chức năng của các gen trong bộ gen người.

Dự án giúp xác định các biến thể di truyền, tạo nền tảng xác định mối quan hệ giữa các đột biến và đặc điểm sinh học. Kết quả của dự án đã mở ra một kỉ nguyên mới cho lĩnh vực khoa học sức khỏe.

2. Một số thành tựu của khoa học dữ liệu

a. Dự án Bộ gen người HGP

KỸ THUẬT NGHIÊN CỨU

Lập bản đồ gen

Giải trình tự gen

Bộ gen người được tạo thành từ khoảng 3 tỉ cặp base:

- Giải trình tự một bộ gen thường sinh ra khoảng một trăm gigabyte dữ liệu.
- Giải trình tự nhiều bộ gen người có thể sinh ra hàng trăm petabyte dữ liệu.

2. Một số thành tựu của khoa học dữ liệu

a. Dự án Bộ gen người HGP

Phân tích dữ liệu hệ gen người

→

Hiểu rõ hơn về cách thức hoạt động của gen, chức năng của gen, mối quan hệ giữa gen và đặc điểm sinh học, sức khoẻ, bệnh tật.

2. Một số thành tựu của khoa học dữ liệu

b. Các dự án nghiên cứu và khám phá không gian

Kính thiên văn Kepler, trong 9 năm hoạt động, đã tạo ra khoảng 678 GB dữ liệu, ghi lại độ sáng của khoảng 150 nghìn ngôi sao.

Các vệ tinh như TESS, K2, Plato thu thập các thông tin về hành tinh như khối lượng, kích thước, mật độ và quỹ đạo, tạo ra khoảng 100 GB dữ liệu mỗi ngày.

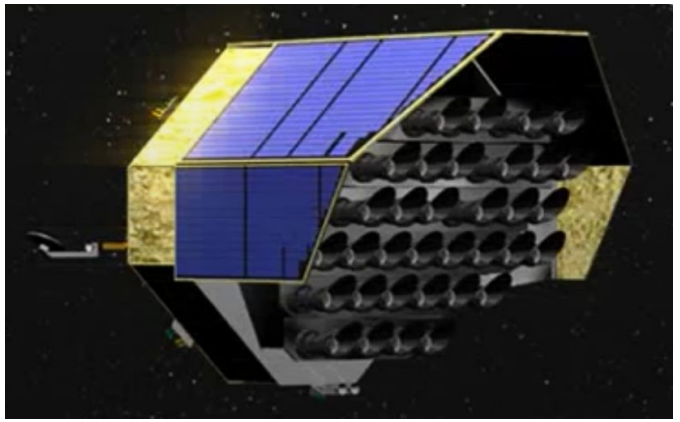

2. Một số thành tựu của khoa học dữ liệu

b. Các dự án nghiên cứu và khám phá không gian

Phát hiện được khoảng 3200 hệ hành tinh quay quanh các ngôi sao trong tổng số khoảng 200 tỉ ngôi sao thuộc dải Ngân Hà

Khoảng 63 hành tinh được xác định có khả năng nuôi dưỡng sự sống.

Để phân tích lượng lớn dữ liệu như vậy, cần phát triển các thuật toán học máy chuyên biệt và phức tạp.

2. Một số thành tựu của khoa học dữ liệu

c. Hệ thống giám sát đánh bắt cá toàn cầu

Hệ thống Giám sát đánh bắt cá toàn cầu (Global Fishing Watch) của Google sử dụng dữ liệu vệ tinh để cung cấp thông tin cho việc ngăn chặn đánh bắt cá bất hợp pháp.

- Xác định mục đích chuyến của mỗi con tàu
- Điểm xuất phát từ quốc gia nào

-> Xác định con tàu đánh bắt cá bất hợp pháp

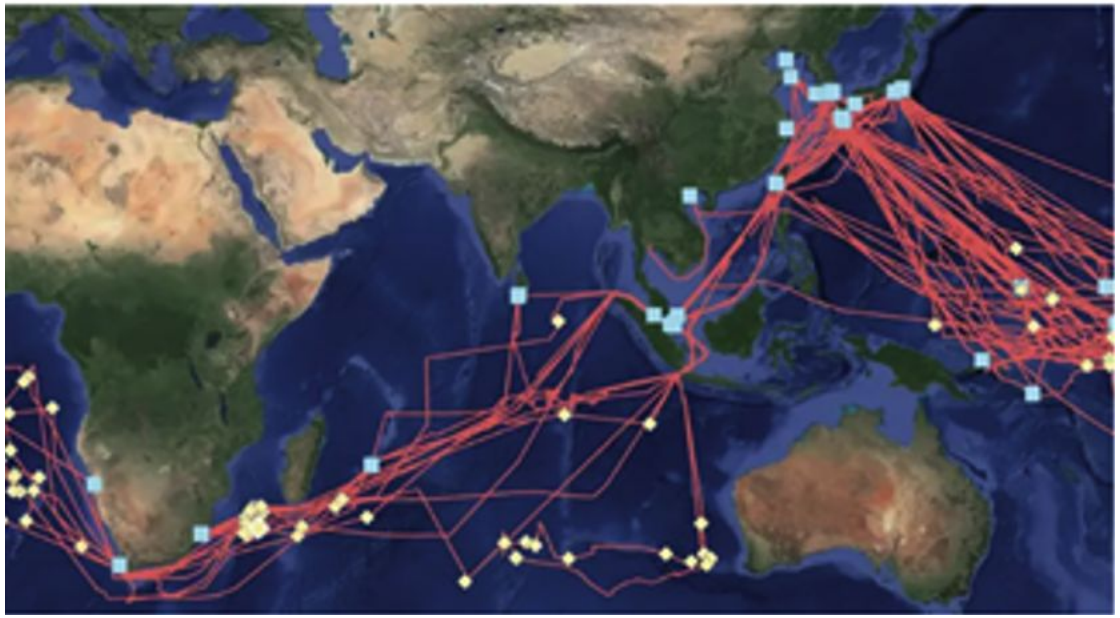

Hình 3. Theo dõi lịch sử hoạt động của tàu biển trên website của Globol Fishing Watch (Nguồn: https://globalfishingwatch.org)

2. Một số thành tựu của khoa học dữ liệu

d. Các mô hình ngôn ngữ lớn

LLM (Large Language Models) là một loại mô hình AI được thiết kế đặc biệt để hiểu ngôn ngữ tự nhiên.

LLM nổi tiếng nhất là GPT-3, có 175 tỉ tham số. Số lượng tham số càng lớn, mô hình càng có thể hiểu và xử lí ngôn ngữ một cách tinh vi hơn.

GPT đã đạt được thành tựu ấn tượng có tính cách mạng trong xử lí ngôn ngữ tự nhiên

2. Một số thành tựu của khoa học dữ liệu

e. Mô hình phát hiện gian lận của American Express

- Năm 2014, lần đầu tiên American Express triển khai mô hình học máy để phát hiện gian lận đã giúp cải thiện 30% so với các hệ thống cũ.
- Năm 2017, American Express đã phát triển một công cụ xác thực nâng cao sử dụng sinh trắc học để xác định ai đang thực hiện giao dịch thẻ tín dụng.

-> Công cụ này đã giúp giảm được 60% giao dịch gian lận.

2. Một số thành tựu của khoa học dữ liệu

e. Mô hình phát hiện gian lận của American Express

- Năm 2014, lần đầu tiên American Express triển khai mô hình học máy để phát hiện gian lận đã giúp cải thiện 30% so với các hệ thống cũ.
- Năm 2017, American Express đã phát triển một công cụ xác thực nâng cao sử dụng sinh trắc học để xác định ai đang thực hiện giao dịch thẻ tín dụng.

-> Công cụ này đã giúp giảm được 60% giao dịch gian lận.

THANK YOU